


多模态 RAG 系统架构



多模态 RAG 系统架构说明

1. 文档处理层

使用 `PyMuPDF (fitz)` 从 PDF 中提取嵌入图片，同时使用 `pdftplumber` 提取文档文本。图片经过压缩（最大 `512px`）后保存到本地磁盘。

2. 图像理解层

通过 `Vision LLM (GLM-4V)` 为每张提取的图片生成文字描述摘要，作为图片的 "语义代理"。摘要文本同时存入向量库供检索。

3. 双路向量索引

文本 `Chunk` 使用智谱 `Embedding-2` 编码为 `1024` 维向量存入 `text_collection`。图片使用 `CLIP ViT-B/32` 编码为 `512` 维向量存入 `image_collection`。两个 `Collection` 使用余弦相似度。

4. 图文联合检索

查询时并行搜索两个 `Collection`，分别返回 `Top-K` 文本和 `Top-M` 图片。结果按相似度归一化后合并返回。

5. 智能模型路由

如果检索结果包含相关图片 (`score > 0.3`)，自动使用 `Vision LLM (GLM-4V)` 进行图文混合推理。纯文本场景使用 `GLM-4-Flash`。

6. Prompt 策略评估

支持 4 种 Prompt 策略并行对比实验：`Basic`（基础指令）、`Few-shot`（示例引导）、`CoT`（思维链）、`Multimodal Step`（图文分步提示）。通过 `LLM-as-Judge` 在 4 个维度上自动评分。

关键技术指标：

- 文本 `Embedding`：智谱 `embedding-2`，`1024-d`
- 图片 `Embedding`：`CLIP ViT-B/32`，`512-d`
- `Vision LLM`：`GLM-4V`
- `Text LLM`：`GLM-4-Flash`
- 向量数据库：`ChromaDB (cosine distance)`